


Comparaison entre modèles économétriques du cours et méthodes de machine learning

Devoir de groupe

1. Objet du devoir

Le présent devoir a pour objectif de vous amener à comparer les performances et les propriétés de modèles économétriques étudiés en détail dans le cours, la régression linéaire et la régression logistique, avec celles de méthodes de **machine learning supervisé** plus sophistiquées, telles que reprises sur le graphique ci-dessous.



Le travail reposera sur l'exploitation d'une base de données choisie par votre groupe et sur l'étude de **deux types de variables dépendantes** :

- une **variable dépendante continue**
- une **variable dépendante binaire**

Vous devrez comparer :

- pour la variable dépendante continue, les résultats d'une **régression linéaire multiple** avec ceux d'au moins **deux méthodes de machine learning adaptées à la régression**.
- pour la variable dépendante binaire, les résultats d'un **modèle logit** avec ceux d'au moins **deux méthodes de machine learning adaptées à la classification**.

L'objectif du devoir n'est pas seulement de produire des résultats empiriques. Il s'agit aussi de démontrer une compréhension réelle du fonctionnement des méthodes mobilisées, de leurs hypothèses, de leurs paramètres, de leurs performances et de leurs limites.

2. Constitution des groupes

Le travail est à réaliser **par groupes de 3 étudiants**. Chaque membre du groupe doit contribuer de manière substantielle à la réalisation du travail et à la présentation orale enregistrée.

3. Choix de la base de données

Chaque groupe est libre de choisir sa base de données pour autant que celle-ci soit :

- **publique ou librement accessible**
- **correctement référencée**
- **suffisamment riche pour permettre une analyse sérieuse**
- **adaptée à la construction de deux problèmes empiriques distincts**, l'un avec variable dépendante continue, l'autre avec variable dépendante binaire

À titre indicatif, les sources suivantes peuvent être utilisées :

- Kaggle : <https://www.kaggle.com/datasets>
- Awesome Public Datasets on GitHub : <https://github.com/awesomedata/awesome-public-datasets?tab=readme-ov-file#economics>
- Google Dataset Search : <https://datasetsearch.research.google.com/>
- GitHub datasets repositories : <https://github.com/orgs/datasets/repositories?type=all>
- UCI Machine Learning Repository : <https://archive.ics.uci.edu/>

Toute autre source publique peut être utilisée à condition qu'elle soit clairement identifiée et justifiée.

4. Exigences minimales

Votre travail devra impérativement respecter les contraintes suivantes.

4.1. Deux variables dépendantes distinctes

Vous devez traiter **deux problèmes empiriques distincts** :

- un problème de **régression** portant sur une **variable dépendante continue**
- un problème de **classification binaire** portant sur une **variable dépendante binaire**

4.2. Variables explicatives

Chaque modèle estimé devra comporter **au moins 5 variables explicatives**.

4.3. Modèles obligatoires

Votre travail devra inclure au minimum :

- **une régression linéaire multiple**
- **un modèle logit**
- **deux modèles de machine learning adaptés à la régression**
- **deux modèles de machine learning adaptés à la classification**

4.4. Langage de programmation

Le code devra être produit en **R et/ou Python**.

5. Remarque importante sur le schéma fourni

Le schéma joint au devoir a pour vocation de vous aider à repérer des familles de méthodes susceptibles d'être explorées. Il ne doit toutefois pas être interprété de manière simpliste.

Tous les éléments qui y figurent ne sont pas de même nature :

- certains correspondent à des **modèles prédictifs supervisés**
- d'autres sont avant tout des outils de **réduction de dimension**
- d'autres encore relèvent de l'**apprentissage non supervisé**

Vous devez donc sélectionner des méthodes **cohérentes avec l'objectif de prédiction poursuivi et adaptées à la nature de la variable dépendante**.

Par exemple, pour une variable continue, il est pertinent de comparer une régression multiple à des méthodes telles que **random forest**, **gradient boosting** ou certains **réseaux de neurones** conçus pour la régression. Pour une variable binaire, il est pertinent de comparer un modèle logit à des méthodes telles que **random forest classifieur**, **support vector machine**, **k-nearest neighbors** ou **gradient boosting classifieur**.

En revanche, des outils comme **PCA** ou certains algorithmes de **clustering** ne constituent pas en eux-mêmes des concurrents directs à la régression multiple ou au logit. Si vous décidez de les utiliser, vous devrez expliquer précisément leur fonction dans votre démarche.

6. Objectifs pédagogiques

Ce devoir poursuit plusieurs objectifs.

6.1. Mobiliser les acquis du cours

Vous devrez réinvestir de manière rigoureuse les méthodes étudiées dans le cours, en particulier :

- la régression linéaire multiple
- le modèle logit

6.2. Découvrir des méthodes plus avancées

Vous devrez recourir à l'IA pour identifier, comprendre et mettre en œuvre des méthodes de machine learning plus sophistiquées.

6.3. Démontrer une compréhension réelle

Le travail devra prouver que vous avez compris :

- l'intuition générale des méthodes utilisées
- leur domaine d'application
- leurs paramètres principaux
- leurs avantages et leurs limites
- les raisons pour lesquelles certains modèles performant mieux ou moins bien selon les cas

L'objectif n'est donc pas de produire un simple assemblage de code, mais de construire une analyse empirique rigoureuse, intelligible et critique.

7. Usage de l'IA

L'usage de l'IA est **autorisé et encouragé** dans le cadre de ce devoir, notamment pour :

- identifier des méthodes pertinentes
- mieux comprendre le fonctionnement d'algorithmes
- obtenir une aide au codage
- déboguer un programme
- suggérer des procédures de validation
- proposer des métriques d'évaluation
- clarifier l'interprétation de certains résultats

Cependant, l'IA ne remplace en aucun cas la compréhension.

Tout groupe incapable d'expliquer clairement le fonctionnement des modèles, les choix de paramétrage, les principales étapes du code et les résultats obtenus s'expose à une pénalisation, même si le code fonctionne.

Il vous appartient donc de montrer que vous avez su :

- comprendre les recommandations reçues
- vérifier leur validité
- les adapter si nécessaire
- corriger d'éventuelles erreurs ou approximations
- exercer un jugement critique

8. Démarche attendue

Votre devoir devra suivre une démarche claire et rigoureuse.

8.1. Présentation de la question étudiée

Vous présenterez :

- la question empirique retenue
- l'intérêt de la base de données choisie
- les deux variables dépendantes étudiées
- la logique du choix des variables explicatives

8.2. Préparation des données

Vous expliquerez :

- la provenance des données
- les éventuelles opérations de nettoyage
- le traitement des valeurs manquantes
- les transformations éventuelles des variables
- la manière dont la variable binaire a été construite si elle n'existe pas directement dans la base
- la justification économique, statistique ou substantielle de vos choix

Toute dichotomisation arbitraire ou insuffisamment justifiée d'une variable continue sera pénalisée.

8.3. Protocole d'estimation et de validation

Vous devrez mettre en place une procédure permettant une comparaison sérieuse entre modèles.

Au minimum, vous devrez :

- distinguer un **échantillon d'apprentissage** et un **échantillon de test**
- comparer tous les modèles sur les **mêmes partitions**
- éviter toute forme de **data leakage**

L'usage d'une validation croisée est encouragé dès lors qu'elle est correctement expliquée et mise en œuvre.

8.4. Estimation des modèles du cours

Vous estimerez :

- une **régression linéaire multiple** pour la variable continue
- un **modèle logit** pour la variable binaire

Vous discuterez notamment :

- la pertinence économique des variables retenues
- les signes obtenus
- l'interprétation des coefficients
- les limites éventuelles de ces modèles
- leur capacité prédictive

8.5. Estimation des modèles de machine learning

Vous estimerez ensuite au moins deux méthodes de machine learning pour chaque type de problème.

Pour chaque méthode, vous devrez expliquer :

- son intuition générale
- le type de problème auquel elle s'applique
- ses principaux hyperparamètres
- la façon dont vous avez choisi ces hyperparamètres
- les avantages et les limites de la méthode
- les risques éventuels d'overfitting

8.6. Comparaison des performances

Vous comparerez les modèles à l'aide d'indicateurs adaptés.

Pour la variable continue, vous pouvez notamment utiliser : RMSE, MAE, R^2 hors échantillon.

Pour la variable binaire, vous pouvez notamment utiliser : accuracy, precision, recall, F1-score, AUC, matrice de confusion.

Vous devez éviter de tirer vos conclusions à partir d'un seul indicateur.

8.7. Discussion finale

Vous devrez discuter de manière argumentée :

- quel modèle semble le plus performant
- si le gain de performance est important ou marginal

- ce que l'on gagne en précision prédictive
- ce que l'on perd éventuellement en lisibilité ou en interprétabilité
- dans quel contexte un modèle simple pourrait rester préférable à un modèle plus complexe

9. Livrables obligatoires

Chaque groupe devra remettre les trois éléments suivants.

9.1. Un code complet en R et/ou Python

Le code devra être lisible, structuré, commenté, reproductible, suffisamment propre pour permettre la réexécution de l'analyse

9.2. Un PowerPoint

Le PowerPoint devra présenter de manière synthétique et rigoureuse la question étudiée, la base de données, les variables, la méthodologie, les modèles estimés, les résultats obtenus, la comparaison finale, les conclusions

9.3. Une vidéo de 15 à 20 minutes

La vidéo devra montrer que vous maîtrisez réellement le travail réalisé.

Elle devra permettre d'évaluer :

- votre compréhension des données
- votre compréhension des modèles du cours
- votre compréhension des modèles de machine learning
- votre compréhension des recommandations fournies par l'IA
- votre capacité à interpréter vos résultats avec recul

Chaque membre du groupe devra intervenir de manière substantielle dans la vidéo.

10. Section obligatoire : usage de l'IA et recul critique

Votre présentation devra obligatoirement comporter une section intitulée :

Usage de l'IA et recul critique

Dans cette section, vous devrez préciser :

- quel ou quels outils d'IA ont été utilisés
- pour quels usages précis
- quels types de recommandations vous ont été fournis
- ce que vous avez retenu
- ce que vous avez modifié
- ce que vous avez rejeté

- au moins un exemple concret de recommandation vérifiée, corrigée ou nuancée par votre groupe

Il ne s'agit pas de reproduire intégralement vos échanges avec un assistant. Il s'agit de montrer que vous avez utilisé l'IA comme **instrument d'apprentissage**, et non comme substitut à votre réflexion.

11. Critères d'évaluation

1. Pertinence de la question et qualité des données

Seront évalués :

- la qualité et l'intérêt de la question empirique
- la pertinence de la base de données choisie
- la cohérence des variables dépendantes et explicatives

2. Préparation des données et rigueur méthodologique

Seront évalués :

- la qualité du nettoyage des données
- le traitement des valeurs manquantes
- la justification des transformations éventuelles
- la rigueur du protocole d'estimation et de validation
- l'absence de biais méthodologiques majeurs

3. Maîtrise des modèles du cours

Seront évalués :

- la qualité de la mise en œuvre de la régression linéaire multiple
- la qualité de la mise en œuvre du logit
- la justesse de l'interprétation économique et statistique

4. Maîtrise des modèles de machine learning

Seront évalués :

- la pertinence du choix des modèles
- la qualité des explications fournies
- la compréhension des hyperparamètres
- la capacité à distinguer performance et interprétabilité

5. Qualité de la comparaison et de la discussion finale

Seront évalués :

- la pertinence des métriques choisies

- la qualité de la comparaison entre modèles
- la capacité à tirer des conclusions nuancées et justifiées

6. Usage de l'IA et recul critique

Seront évalués :

- l'usage intelligent des outils d'IA
- la capacité à vérifier et corriger les suggestions reçues
- la preuve d'une compréhension personnelle du travail réalisé

7. Qualité des livrables

Seront évalués :

- la propreté du code
- la clarté du PowerPoint
- la qualité pédagogique de la vidéo
- la participation équilibrée des membres du groupe

12. Conseils méthodologiques

Un bon devoir n'est pas un devoir qui accumule mécaniquement le plus grand nombre possible d'algorithmes.

Un bon devoir est un devoir qui :

- pose une question claire
- mobilise des données pertinentes
- choisit des méthodes adaptées
- compare les modèles proprement
- interprète les résultats avec rigueur
- démontre une compréhension réelle

Un modèle plus complexe n'est pas automatiquement supérieur à un modèle plus simple. Une conclusion bien argumentée peut parfaitement montrer qu'un modèle du cours reste préférable dans certains contextes, notamment lorsque l'interprétabilité joue un rôle central.

13. Récapitulatif des exigences minimales

Votre devoir devra impérativement contenir :

- un groupe de **3 étudiants**
- une base de données clairement référencée
- **2 variables dépendantes distinctes :**
 - **1 continue**

- **1 binaire**
- **au moins 5 variables explicatives**
- **1 régression linéaire multiple**
- **1 modèle logit**
- **au moins 2 modèles de machine learning pour la régression**
- **au moins 2 modèles de machine learning pour la classification**
- **un code en R et/ou Python**
- **un PowerPoint**
- **une vidéo de 15 à 20 minutes**
- **une section obligatoire sur l'usage de l'IA et le recul critique**

14. Modalités pratiques

Date de remise : 15 juin 2026

Mode de remise : Par WeTransfer

Nom des fichiers : GROUPEXX.zip (fichier compressé comprenant une vidéo, un powerpoint, un code)